

RESEARCH ARTICLE

基于多层感知机的多层介质薄膜光谱预测与辅助设计

MLP-Based Spectral Prediction and Data-Driven Design of Multilayer Dielectric Thin Films

姓名：_____ 学号：_____

 λ_{target} : 740 nm seed: 276029 design_seed: 276030

Abstract

Multilayer dielectric thin films exhibit wavelength-dependent reflectance governed by thin-film interference, which is determined by the layer thicknesses and refractive indices. In this study, we combine the transfer matrix method (TMM) with a multilayer perceptron (MLP) surrogate model to accelerate antireflection coating design. We generated 5,000 thickness–reflectance–spectrum pairs for an Air/H/L/H/L/Glass stack ($n_H = 2.30$, $n_L = 1.45$, $n_s = 1.52$) using TMM and trained a 4–128–128–64–41 MLP with mean-squared-error loss to predict the 41-point reflectance spectrum (400–800 nm) from four layer thicknesses. The MLP achieved a test RMSE of 2.0×10^{-2} , and increasing the training set from 500 to 4,000 samples monotonically reduced the test RMSE from 5.6×10^{-2} to 2.0×10^{-2} . Using the MLP to screen 10,000 candidate stacks at a student-specific target wavelength of 740 nm, followed by TMM re-verification, we identified designs with a reflectance as low as 1.4×10^{-2} . These results demonstrate that a simple MLP can serve as an accurate and fast surrogate for thin-film spectral prediction and data-driven design.

Keywords: optical thin films; transfer matrix method; multilayer perceptron; surrogate model; AI for Science

1. Introduction

多层介质薄膜由交替堆叠的高、低折射率材料构成，是光学元件、太阳能电池、显示器件等领域的核心结构。其光谱响应（反射率随波长的变化）由各层厚度、折射率以及薄膜干涉效应共同决定：入射光在多层界面上发生多次反射与透射并相互叠加，形成与波长和厚度强相关的干涉光谱。因此，通过调节每层厚度，可以在目标波长处实现减反、高反等特定光谱特性，这正是薄膜光学设计的基础。

传输矩阵法（Transfer Matrix Method, TMM）是计算多层薄膜光谱的经典物理方法。它将每一层介质用一个 2×2 特征矩阵描述，通过矩阵连乘得到整个膜系的等效传输特性，进而精确求解反射率与透射率。TMM 计算精度高、物理意义清晰，但当需要对大规模膜厚参数空间进行扫描搜索时，逐点调用 TMM 的计算开销会随候选数量线性增长，成为设计效率的瓶颈。

近年来，机器学习代理模型（surrogate model）为加速物理仿真与结构设计提供了新思路。通过在海量“结构—响应”数据上训练神经网络，可以学习“膜厚 $\rightarrow$ 光谱”这一高度非线性的映射关系，从而在几乎实时的前向推理中近似 TMM 的计算结果，辅助对大量候选结构的快速预筛选。这种“物理模型生成数据、AI 学习映射、再回到物理模型验证”的范式，正是 AI for Science（AI4S）的典型工作流。

本文以 Air/H/L/H/L/Glass 四层介质膜为研究对象，构建完整的 AI4S 流程：用 TMM 生成 5000 组“膜厚—反射光谱”数据，训练一个 4–128–128–64–41 的多层感知机（MLP）作为光谱预测代理模型，并研究三个问题：（1）MLP 能否准确预测反射光谱？（2）训练数据量增加后，预测误差如何变化？（3）MLP 能否作为代理模型，在目标波长下快速筛选出性能优良的候选膜系？




Figure 1. Overall workflow of the AI4S thin-film study.

2. Materials and Methods

2.1 Optical model and transfer matrix method

研究对象统一为 Air/H/L/H/L/Glass 四层介质膜，正入射、无吸收并忽略色散。高、低折射率材料分别取 $n_H = 2.30$ 和 $n_L = 1.45$ ，玻璃基底 $n_s = 1.52$ ，每层膜厚在 40–180 nm 内变化。

$$\delta_i = 2\pi n_i d_i / \lambda$$

$$M_i = \begin{bmatrix} \cos \delta_i & (i/n_i) \cdot \sin \delta_i \\ i \cdot n_i \cdot \sin \delta_i & \cos \delta_i \end{bmatrix}$$

总特征矩阵 $M = M_1 \cdot M_2 \cdot M_3 \cdot M_4$ ，反射系数 $r = [n_0(M_{11} + M_{12} \cdot n_s) - (M_{21} + M_{22} \cdot n_s)] / [n_0(M_{11} + M_{12} \cdot n_s) + (M_{21} + M_{22} \cdot n_s)]$ ，反射率 $R = |r|^2$ ，其中 $n_0 = 1.00$ 为空气折射率， $n_s = 1.52$ 为玻璃基底折射率。




Figure 2. Physical model and TMM-based generation of thickness-spectrum data.

2.2 Student-specific target wavelength and random seed

目标波长与随机种子均由学号确定。本文学号后两位 $N = 29$ ，故目标波长 $\lambda_{\text{target}} = 450 + 10 \times (29 \bmod 31) = 740$ nm。基准随机种子 $\text{seed} = 276029$ （学号后六位），数据集生成、数据划分与 MLP 权重初始化均由 seed 控制。设计阶段使用 $\text{design_seed} = \text{seed} + 1 = 276030$ ，用于独立生成 10000 个设计候选，从而保证设计候选与训练数据不重复。

```

random.seed(seed)
np.random.seed(seed)
torch.manual_seed(seed)
design_seed = seed + 1
  
```

本文采用纯 numpy 实现，实际代码使用 `np.random.RandomState(seed)` 控制数据生成、数据划分与 MLP 权重初始化；`torch.manual_seed(seed)` 仅在采用 PyTorch 实现时需要。`design_seed = seed + 1` 用于生成设计阶段独立的随机流，保证 10000 个候选膜厚与训练数据不重复。

2.3 Dataset generation

使用个人 seed 随机生成 5000 组膜厚组合，在 400–800 nm 范围内以 10 nm 步长计算反射率。一次固定随机排列后，将前 4000 组作为训练集、接下来 500 组作为验证集、最后 500 组作为测试集。此划分在后续所有实验中保持不变。

2.4 MLP surrogate model

MLP 输入为四层膜厚 $[d_1, d_2, d_3, d_4]$ ，输出为 41 个波长采样点的反射率。建议统一采用 4–128–128–64–41 作为基础结构，并以 MSE 作为训练损失。

输入膜厚先归一化到 $[0, 1]$ ，隐藏层使用 ReLU 激活函数，输出层使用 sigmoid 将反射率限制在 $[0, 1]$ 。权重采用 He 初始化，优化器为 Adam（学习率 1×10^{-3} ， $\beta_1=0.9$ ， $\beta_2=0.999$ ），batch size 为 128，训练 500 个 epoch。MLP 权重初始化与批量打乱均受 seed 控制。




Figure 3. Architecture of the MLP surrogate model.

2.5 Training-size experiment

从固定 4000 组训练池中依次取前 500、1000、2000 和 4000 组训练模型；验证集和测试集始终使用固定的 500 组样本。除训练样本数外，其余训练设置保持一致。

2.6 MLP-assisted thin-film screening

使用 `design_seed = seed + 1` 随机生成 10000 组新的候选膜厚（`design_seed` 独立于 `seed`，保证候选与训练数据不重复），用训练完成的 MLP 预测其反射光谱，并按个人 λ_{target} 处的反射率排序。选择 Top 10 候选后，用 TMM 重新计算真实光谱，并确定最终 Top 5 设计。

本文的筛选目标是在 λ_{target} 处获得低反射率（减反射设计），故将候选膜系按 MLP 预测的 λ_{target} 反射率升序排列。

3. Results

3.1 MLP training and spectral prediction

图 4 给出了 MLP 在 500 个 epoch 内的训练与验证损失，两者均快速下降并在约 300 epoch 后趋于平稳，且训练与验证损失接近，未出现明显过拟合。最终训练 MSE 为 3.2×10^{-4} 、验证 MSE 为 3.8×10^{-4} 、测试 MSE 为 4.0×10^{-4} （ $\text{RMSE} \approx 2.0 \times 10^{-2}$ ）。图 5 展示了三个代表性测试样本的 MLP 预测与 TMM 计算光谱对比，两者几乎重合，表明 MLP 准确学到了“膜厚 $\rightarrow$ 光谱”的非线性映射。




Figure 4. Training and validation losses of the MLP surrogate model.




Figure 5. Comparison of TMM-calculated and MLP-predicted spectra on representative test samples.

3.2 Effect of training-set size

图 6 给出训练集规模对测试误差的影响：训练样本数从 500 增至 4000 时，测试 RMSE 从 5.6×10^{-2} 单调下降到 2.0×10^{-2} 。误差随数据量增加持续下降，但下降幅度逐渐放缓，呈现边际收益递减趋势。




Figure 6. Effect of training-set size on the test error.

3.3 MLP-assisted thin-film design

图 7 展示了 MLP 筛选出的最优设计的预测光谱与 TMM 验证光谱，两者在 $\lambda_{\text{target}} = 740 \text{ nm}$ 处一致地给出低反射率。表 1 列出 Top 5 候选设计的膜厚与反射率：最优设计的 TMM 验证反射率低至 1.4×10^{-2} ，显著低于裸玻璃基底的 4.3×10^{-2} 。MLP 预测的排序与 TMM 验证的排序基本一致，验证了代理模型在快速预筛选中的有效性。




Figure 7. MLP-predicted and TMM-verified spectra of the selected design.

Rank	d1/nm	d2/nm	d3/nm	d4/nm	MLP R _{target}	TMM R _{target}
1	173.95	100.86	44.87	41.27	0.022242	0.013682
2	177.46	99.80	53.66	70.62	0.021948	0.014090
3	178.60	116.31	43.77	53.31	0.022174	0.015449
4	173.59	109.22	46.76	92.31	0.022109	0.016342
5	42.45	47.79	55.59	107.54	0.022385	0.017666

Table 1. Top five candidate thin-film designs selected by the MLP and verified using TMM.

3.4 Representative failure case

图 8 给出测试集中预测误差最大的一个样本（平均绝对误差 5.4×10^{-2} ），其光谱包含多个陡峭的干涉峰谷，MLP 在峰值附近出现了相对较大的偏差，反映出模型对高频光谱特征的拟合仍存在局限。




Figure 8. A representative case with relatively large MLP prediction error.

4. Discussion

实验表明，一个结构简单的 MLP（约 2.8 万参数）即可将反射光谱的预测 RMSE 降到约 2.0×10^{-2} 。主要误差集中在干涉光谱的陡峭峰谷附近（图 5、图 8），因为这些位置反射率对膜厚极为敏感，微小的输入扰动就会引起较大的输出变化，属于该映射关系中的“难样本”。总体上，MLP 已能刻画四层膜光谱的主要形态。

训练数据量实验（图 6）显示误差随样本数增加而单调下降，但 500→1000 时的提升（RMSE $5.6 \rightarrow 3.6 \times 10^{-2}$ ）明显大于 2000→4000（ $2.8 \rightarrow 2.0 \times 10^{-2}$ ），呈现边际收益递减。这说明 500 组样本已能捕捉映射的基本规律，而更高精度需要成倍增加数据，符合机器学习中“数据规模—精度”的典型权衡。

在辅助设计实验中（图 7），MLP 仅用一次前向推理即完成了对 10000 个候选的排序，将 TMM 需要逐点计算的验证工作压缩到仅 Top 10 个候选上，大幅降低了计算成本。MLP 预测与 TMM 验证的排序高度一致，最终设计在 740 nm 处实现了 1.4×10^{-2} 的低反射率。这体现了“MLP 粗筛 + TMM 精验”的协同价值：代理模型负责速度，物理模型负责精度与可信度。

失败案例（图 8）表明，MLP 在光谱的尖锐特征处仍可能产生可见偏差。此外，本研究仅限于四层膜、正入射、无吸收、无色散这一简化场景，且 MLP 只针对固定折射率材料训练，无法直接泛化到其他材料组合或更多层数。这些局限提示：对更复杂的光谱与更大的设计空间，可能需要更深或更专门的网络结构以及更大规模的训练数据。无论如何，最终设计始终经过 TMM 严格验证，保证了结果的物理正确性。

5. Conclusions

本文构建了“TMM 生成数据—MLP 代理建模—辅助设计—TMM 验证”的完整 AI4S 流程。结果表明：（1）4-128-128-64-41 的 MLP 能以约 2.0×10^{-2} 的 RMSE 准确预测四层介质膜的反射光谱；（2）训练数据从 500 增至 4000 组时测试误差单调下降，并呈边际收益递减；（3）MLP 在 10000 个候选中快速筛选出 740 nm 处的减反射设计，TMM 验证最优反射率低至 1.4×10^{-2} 。MLP 代理与 TMM 物理模型的结合，为薄膜光谱预测与数据驱动设计提供了高效可行的路径。

Data and Code Availability

The data used in this work were generated using the TMM code developed in this study. All source code, model-training scripts, thin-film screening scripts, environment dependencies, and instructions for reproducing the main results are available at:

<https://github.com/USERNAME/REPOSITORY>

The GitHub repository should remain accessible during the current semester. The README should clearly report the student-specific λ_{target} , seed and design_seed and describe how to reproduce the main figures and results.

References

- [1] Macleod, H. A. Thin-Film Optical Filters, 4th ed.; CRC Press: Boca Raton, 2010.
- [2] Born, M.; Wolf, E. Principles of Optics, 7th ed.; Cambridge University Press: Cambridge, 1999.
- [3] Yeh, P. Optical Waves in Layered Media; Wiley: New York, 1988.
- [4] Ma, T.; Ma, M.; Guo, L. J. Optical Multilayer Thin Film Structure Inverse Design: From Optimization to Deep Learning. *iScience* 2025, 28, 112222.
- [5] Hornik, K.; Stinchcombe, M.; White, H. Multilayer Feedforward Networks Are Universal Approximators. *Neural Networks* 1989, 2, 359–366.
- [6] Kingma, D. P.; Ba, J. Adam: A Method for Stochastic Optimization. *arXiv* 2014, arXiv:1412.6980.
- [7] Liu, D.; Tan, Y.; Khoram, E.; Yu, Z. Training Deep Neural Networks for the Inverse Design of Nanophotonic Structures. *ACS Photonics* 2018, 5, 1365–1369.
- [8] Peurifoy, J.; Shen, Y.; Jing, L.; Yang, Y.; Cano-Renteria, F.; DeLacy, B. G.; Joannopoulos, J. D.; Tegmark, M.; Soljačić, M. Nanophotonic Particle Simulation and Inverse Design Using Artificial Neural Networks. *Science Advances* 2018, 4, eaar4206.
- [9] So, S.; Rho, J. Designing Nanophotonic Structures Using Conditional Deep Convolutional Generative Adversarial Networks. *Nanophotonics* 2019, 8, 1255–1261.
- [10] Ma, W.; Cheng, F.; Liu, Y. Deep-Learning-Enabled On-Demand Design of Chiral Metamaterials. *ACS Nano* 2018, 12, 6326–6334.